

# SD 204

## SVD / PCA

**Joseph Salmon**

<http://josephsalmon.eu>

Télécom Paristech, Institut Mines-Télécom

# Plan

## Algèbre linéaire

- SVD

- Pseudo-inverse

- Stabilité numérique

## ACP

- Définition

- Interprétation et récursion

# Sommaire

## Algèbre linéaire

SVD

Pseudo-inverse

Stabilité numérique

## ACP

Définition

Interprétation et récursion

# La décomposition spectrale

## Théorème spectral

Une matrice symétrique  $S \in \mathbb{R}^{n \times n}$  est diagonalisable en base orthonormée, *i.e.*, il existe  $\lambda_1 \geq \dots \geq \lambda_n$  et une matrice orthogonale  $U \in \mathbb{R}^{n \times n}$  telle que :

$$S = U \operatorname{diag}(\lambda_1, \dots, \lambda_n) U^\top \text{ ou } SU = U \operatorname{diag}(\lambda_1, \dots, \lambda_n)$$

Rem: Si l'on écrit  $U = [\mathbf{u}_1, \dots, \mathbf{u}_n]$  cela signifie que :

$$S = \sum_{i=1}^n \lambda_i \mathbf{u}_i \mathbf{u}_i^\top$$

De plus  $\forall i \in \llbracket 1, n \rrbracket$ ,  $S\mathbf{u}_i = \lambda_i \mathbf{u}_i$

Rappel : une matrice orthogonale  $U \in \mathbb{R}^n$  est une matrice telle que  $U^\top U = UU^\top = \operatorname{Id}_n$  ou  $\forall i, j = 1, \dots, n$ ,  $\mathbf{u}_i^\top \mathbf{u}_j = \langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{i,j}$

Vocabulaire : les  $\lambda_i$  sont les **valeurs propres** de  $S$  et les  $\mathbf{u}_i \in \mathbb{R}^n$  sont les **vecteurs propres** associés

# La décomposition en valeurs singulières ( : *Singular Value Decomposition, SVD*)

## Théorème

Pour toute matrice  $X \in \mathbb{R}^{n \times p}$ , il existe une matrice orthogonale  $U \in \mathbb{R}^{n \times n}$  et une matrice orthogonale  $V \in \mathbb{R}^{p \times p}$ , telles que  
$$U^T X V = \text{diag}(s_1, \dots, s_{\min(n,p)}) = \Sigma \in \mathbb{R}^{n \times p}$$

avec  $s_1 \geq s_2 \geq \dots \geq s_{\min(n,p)} \geq 0$ , ou encore :

$$X = U \Sigma V^T$$

avec  $U = [\mathbf{u}_1, \dots, \mathbf{u}_n]$  et  $V = [\mathbf{v}_1, \dots, \mathbf{v}_p]$

Rappel : 
$$\begin{cases} \langle \mathbf{u}_i, \mathbf{u}_j \rangle = \delta_{i,j}, & \forall i, j \in \llbracket 1, n \rrbracket \\ \langle \mathbf{v}_i, \mathbf{v}_j \rangle = \delta_{i,j}, & \forall i, j \in \llbracket 1, p \rrbracket \end{cases}$$

Démonstration : diagonaliser  $X^T X$  Golub et Van Loan (1996)

## SVD la suite

Vocabulaire : les  $s_j$  sont les **valeurs singulières** de  $X$  ; les  $\mathbf{u}_j$  (resp.  $\mathbf{v}_j$ ) sont les **vecteurs singuliers à gauche** (resp. droite)

Propriété variationnelle de la plus grande valeur singulière

$$s_1 = \begin{cases} \max_{\mathbf{u} \in \mathbb{R}^n, \mathbf{v} \in \mathbb{R}^p} \mathbf{u}^\top X \mathbf{v} \\ \text{s.c. } \|\mathbf{u}\|^2 = 1 \text{ et } \|\mathbf{v}\|^2 = 1 \end{cases}$$

Lagrangien :  $\mathcal{L}(\mathbf{u}, \mathbf{v}) = \mathbf{u}^\top X \mathbf{v} - \lambda_1(\|\mathbf{u}\|^2 - 1) - \lambda_2(\|\mathbf{v}\|^2 - 1)$

$$\text{CNO : } \begin{cases} \nabla_{\mathbf{u}} \mathcal{L} = X \mathbf{v} - 2\lambda_1 \mathbf{u} = 0 \\ \nabla_{\mathbf{v}} \mathcal{L} = X^\top \mathbf{u} - 2\lambda_2 \mathbf{v} = 0 \end{cases} \iff \begin{cases} X \mathbf{v} = 2\lambda_1 \mathbf{u} \\ X^\top \mathbf{u} = 2\lambda_2 \mathbf{v} \end{cases} \Rightarrow \begin{cases} X^\top X \mathbf{v} = \alpha \mathbf{v} \\ X X^\top \mathbf{u} = \alpha \mathbf{u} \end{cases}$$

avec  $\alpha = 2\lambda_1\lambda_2$ , et donc  $\mathbf{v}$  et  $\mathbf{u}$  sont des vecteurs propres de  $X^\top X$  et de  $XX^\top$

# La SVD toujours et encore

## SVD compacte

On ne garde que les éléments non-nuls de la diagonale

$$X = \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^\top = U_r \operatorname{diag}(s_1, \dots, s_r) V_r^\top$$

avec  $s_i > 0, \forall i \in \llbracket 1, r \rrbracket$  et  $U_r = [\mathbf{u}_1, \dots, \mathbf{u}_r]$ ,  $V_r = [\mathbf{v}_1, \dots, \mathbf{v}_r]$

Rem:  $r = \operatorname{rg}(X)$  nombre de valeurs singulières (non-nulles)

Rem: les matrices  $\mathbf{u}_i \mathbf{v}_i^\top$  sont toutes de rang 1

Rem: les vecteurs  $\mathbf{u}_i$  (resp. les vecteurs  $\mathbf{v}_i^\top$ ) sont des vecteurs orthonormaux qui engendrent le même espace que celui engendré par les colonnes (resp. les lignes) de  $X$

$$\operatorname{vect}(\mathbf{x}_1, \dots, \mathbf{x}_p) = \operatorname{vect}(\mathbf{u}_1, \dots, \mathbf{u}_r)$$

# SVD et meilleure approximation

## Théorème (meilleure approximation de rang $k$ )

Prenons la SVD de  $X \in \mathbb{R}^{n \times p}$  donnée par  $X = \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^\top$  (i.e.,  $r = \text{rg}(X)$ ). Si  $k < r$  et si  $X_k = \sum_{i=1}^k s_i \mathbf{u}_i \mathbf{v}_i^\top$  alors

$$\min_{Z \in \mathbb{R}^{n \times p} : \text{rg}(Z)=k} \|X - Z\|_2 = \|X - X_k\|_2 = s_{k+1}$$

Rem: la norme spectrale de  $X$  est définie par

$$\|X\|_2 = \sup_{u \in \mathbb{R}^p, \|u\|=1} \|Xu\| = s_1(X)$$

Rem: ce théorème est aussi crucial pour l'analyse en composante principale (ACP)



# Sommaire

## Algèbre linéaire

SVD

Pseudo-inverse

Stabilité numérique

## ACP

Définition

Interprétation et récursion

# Pseudo-inverse

## Définition

Si  $X \in \mathbb{R}^{n \times p}$  admet pour SVD  $X = \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^\top$  alors sa **pseudo-inverse**  $X^+ \in \mathbb{R}^{p \times n}$  est définie par :

$$X^+ = \sum_{i=1}^r \frac{1}{s_i} \mathbf{v}_i \mathbf{u}_i^\top$$

Rem: Si  $X \in \mathbb{R}^{n \times n}$  est inversible (i.e., de rang  $n$ ) alors  $X = \sum_{i=1}^n s_i \mathbf{u}_i \mathbf{v}_i^\top$  et alors  $X^+ = X^{-1}$

Démonstration :

$$\begin{aligned} XX^+ &= \sum_{j=1}^n s_j \mathbf{u}_j \mathbf{v}_j^\top \sum_{i=1}^n \frac{1}{s_i} \mathbf{v}_i \mathbf{u}_i^\top \\ &= \sum_{j=1}^n \sum_{i=1}^n s_j \frac{1}{s_i} \mathbf{u}_j \mathbf{v}_j^\top \mathbf{v}_i \mathbf{u}_i^\top \\ &= \sum_{j=1}^n \sum_{i=1}^n s_j \frac{1}{s_i} \delta_{i,j} \mathbf{u}_j \mathbf{u}_i^\top = \sum_{i=1}^n \mathbf{u}_i \mathbf{u}_i^\top = \text{Id}_n \end{aligned}$$

# SVD et numérique

Les fonctions SVD et pseudo-inverse sont disponibles dans toutes bibliothèques numériques, par exemple Numpy

- ▶ Pseudo-inverse : `U, s, V = np.linalg.svd(X)`

Attention dans ce cas :

`X=np.dot(U, np.dot(np.diag(S), V))`

Il y a aussi plusieurs variantes matrice pleine ou non

cf. `full_matrices=True/False`

- ▶ Pseudo-inverse : `Xinv = np.linalg.pinv(X)`

---

**Exo:** Vérifier numériquement le théorème de meilleure approximation de rang fixé pour une matrice tirée aléatoirement selon une loi gaussienne (e.g., de taille  $9 \times 6$ , pour  $k = 3$ )

---

# Sommaire

## Algèbre linéaire

SVD

Pseudo-inverse

Stabilité numérique

## ACP

Définition

Interprétation et récursion

## Quelques mots de stabilité numérique

Prenons  $\hat{\boldsymbol{\theta}} = X^+ \mathbf{y}$  comme solution des moindres carrés.

Supposons qu'on observe maintenant non plus  $\mathbf{y}$  mais  $\mathbf{y} + \Delta$  où  $\Delta$  est une erreur très petite :  $\|\Delta\| \ll \|\mathbf{y}\|$ .

Alors l'estimateur des moindres carrés pour  $\mathbf{y} + \Delta$  par  $X$  donne

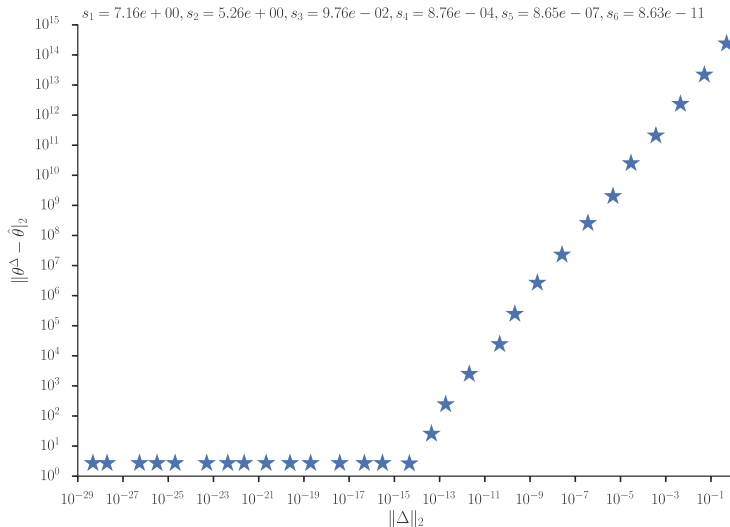
$$\hat{\boldsymbol{\theta}}^\Delta = X^+(\mathbf{y} + \Delta)$$

$$\hat{\boldsymbol{\theta}}^\Delta = \hat{\boldsymbol{\theta}} + X^+ \Delta$$

$$\hat{\boldsymbol{\theta}}^\Delta = \hat{\boldsymbol{\theta}} + \sum_{i=1}^r \frac{1}{s_i} \mathbf{v}_i \mathbf{u}_i^\top \Delta$$

# Exemple de problème de conditionnement

$X \in \mathbb{R}^{10 \times 6}$  dont les valeurs singulières sont ci-dessous :



## Prochains cours : remèdes possibles

- Régulariser le spectre / les valeurs singulières
- Contraindre les coefficients de  $\hat{\theta}$  à n'être pas trop grands

Une solution rendant ces deux points de vue équivalents : *Ridge Regression* / Régularisation de Tychonoff

# Sommaire

## Algèbre linéaire

SVD

Pseudo-inverse

Stabilité numérique

## ACP


Définition

Interprétation et récursion



# ACP

On observe  $n$  points  $x_1, \dots, x_n$  dans  $\mathbb{R}^p$ , ainsi on crée une matrice  $X = [x_1, \dots, x_n]^\top$  matrice  $n \times p$  :  $n$  observations (lignes),  $p$  *features* (colonnes)



Rem: on doit recentrer les points pour qu'ils aient une moyenne nulle  $X \leftarrow [x_1 - \bar{x}_n, \dots, x_n - \bar{x}_n]^\top = X - \mathbf{1}_n \bar{x}_n^\top$  (on peut aussi mettre à l'échelle pour avoir un écart-type similaire par *feature*)

# Analyse en Composante Principale, ACP

( : *Principal Component Analysis, PCA*)

Paramètre  $k$  : nombre d'axes pour représenter un nuage de  $n$  points  $(x_1, \dots, x_n)$ , représentés par les lignes de  $X \in \mathbb{R}^{n \times p}$ .

Cette méthode **compresse** le nuage de points de dimension  $p$  en un nuage de dimension  $k$

L'ACP (de niveau  $k$ ) consiste à effectuer la SVD de  $X$ , et à ne garder que les  $k$  axes principaux pour représenter le nuage.

$$X = \sum_{i=1}^r s_i \mathbf{u}_i \mathbf{v}_i^\top \longrightarrow \sum_{i=1}^k s_i \mathbf{u}_i \mathbf{v}_i^\top$$

On appelle **axes principaux** les  $k$  vecteurs  $\mathbf{v}_1, \dots, \mathbf{v}_k$ , et en général  $k \ll p$  (e.g.,  $k = 2$ , pour une visualisation planaire)

# Sommaire

## Algèbre linéaire

SVD

Pseudo-inverse


Stabilité numérique

## ACP


Définition

Interprétation et récursion

## Axe principal : maximisation de la variance




## Axe principal : maximisation de la variance




Data and mean


# Axe principal : maximisation de la variance




Data, mean and projection




# Axe principal : maximisation de la variance




Data, mean and projection



# Axe principal : maximisation de la variance




Data, mean and projection







# Axe principal : maximisation de la variance




Data, mean and projection




# Axe principal : maximisation de la variance




Data, mean and projection




# Axe principal : maximisation de la variance




Data, mean and projection




# Axe principal : maximisation de la variance




Data, mean and projection




# Axe principal : maximisation de la variance




Data, mean and projection




# Axe principal : maximisation de la variance




Data, mean and projection




# Axe principal : maximisation de la variance




Data, mean and projection



# Axe principal : maximisation de la variance



Principal direction (main axis)



Angle



## ACP : axe principal

L'axe principal (normalisé)  $\mathbf{v}_1$  est la solution du problème :

$$\mathbf{v}_1 \in \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \mathbf{v}^\top X^\top X \mathbf{v} = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \|X\mathbf{v}\|^2 = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \sum_{i=1}^n (x_i^\top \mathbf{v})^2$$

Rem: après recentrage le dernier terme est la variance du nuage de points projeté sur l'axe  $\mathbf{v}$

---

**Algorithme** : Méthode de la puissance itérée

---

**Entrées** :  $X \in \mathbb{R}^{n \times p}$ , itérations  $K$

---

---

Rem: on résout une maximisation sous contrainte convexe

## ACP : axe principal

L'axe principal (normalisé)  $\mathbf{v}_1$  est la solution du problème :

$$\mathbf{v}_1 \in \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \mathbf{v}^\top X^\top X \mathbf{v} = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \|X\mathbf{v}\|^2 = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \sum_{i=1}^n (x_i^\top \mathbf{v})^2$$

Rem: après recentrage le dernier terme est la variance du nuage de points projeté sur l'axe  $\mathbf{v}$

---

**Algorithme** : Méthode de la puissance itérée

---

**Entrées** :  $X \in \mathbb{R}^{n \times p}$ , itérations  $K$

$\mathbf{v}$  tiré aléatoirement dans  $\mathbb{R}^{n \times p}$  (e.g.,  $u/\|u\|$  avec  $u$  gaussien)

---

Rem: on résout une maximisation sous contrainte convexe

## ACP : axe principal

L'axe principal (normalisé)  $\mathbf{v}_1$  est la solution du problème :

$$\mathbf{v}_1 \in \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \mathbf{v}^\top X^\top X \mathbf{v} = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \|X \mathbf{v}\|^2 = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \sum_{i=1}^n (x_i^\top \mathbf{v})^2$$

Rem: après recentrage le dernier terme est la variance du nuage de points projeté sur l'axe  $\mathbf{v}$

---

**Algorithme :** Méthode de la puissance itérée

---

**Entrées :**  $X \in \mathbb{R}^{n \times p}$ , itérations  $K$

$\mathbf{v}$  tiré aléatoirement dans  $\mathbb{R}^{n \times p}$  (e.g.,  $u/\|u\|$  avec  $u$  gaussien)

**pour**  $k = 1, \dots, K$  **faire**

|

---

Rem: on résout une maximisation sous contrainte convexe

## ACP : axe principal

L'axe principal (normalisé)  $\mathbf{v}_1$  est la solution du problème :

$$\mathbf{v}_1 \in \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \mathbf{v}^\top X^\top X \mathbf{v} = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \|X\mathbf{v}\|^2 = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \sum_{i=1}^n (x_i^\top \mathbf{v})^2$$

Rem: après recentrage le dernier terme est la variance du nuage de points projeté sur l'axe  $\mathbf{v}$

---

**Algorithme :** Méthode de la puissance itérée

---

**Entrées :**  $X \in \mathbb{R}^{n \times p}$ , itérations  $K$

$\mathbf{v}$  tiré aléatoirement dans  $\mathbb{R}^{n \times p}$  (e.g.,  $u/\|u\|$  avec  $u$  gaussien)

**pour**  $k = 1, \dots, K$  **faire**

$\mathbf{w} \leftarrow X\mathbf{v}$

---

Rem: on résout une maximisation sous contrainte convexe

## ACP : axe principal

L'axe principal (normalisé)  $\mathbf{v}_1$  est la solution du problème :

$$\mathbf{v}_1 \in \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \mathbf{v}^\top X^\top X \mathbf{v} = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \|X\mathbf{v}\|^2 = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \sum_{i=1}^n (x_i^\top \mathbf{v})^2$$

Rem: après recentrage le dernier terme est la variance du nuage de points projeté sur l'axe  $\mathbf{v}$

---

**Algorithme** : Méthode de la puissance itérée

---

**Entrées** :  $X \in \mathbb{R}^{n \times p}$ , itérations  $K$

$\mathbf{v}$  tiré aléatoirement dans  $\mathbb{R}^{n \times p}$  (e.g.,  $u/\|u\|$  avec  $u$  gaussien)

**pour**  $k = 1, \dots, K$  **faire**

$\mathbf{w} \leftarrow X\mathbf{v}$

$\mathbf{v} \leftarrow X^\top \mathbf{w}$

---

Rem: on résout une maximisation sous contrainte convexe

# ACP : axe principal

L'axe principal (normalisé)  $\mathbf{v}_1$  est la solution du problème :

$$\mathbf{v}_1 \in \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \mathbf{v}^\top X^\top X \mathbf{v} = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \|X \mathbf{v}\|^2 = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \|\mathbf{v}\|=1} \sum_{i=1}^n (x_i^\top \mathbf{v})^2$$

Rem: après recentrage le dernier terme est la variance du nuage de points projeté sur l'axe  $\mathbf{v}$

---

**Algorithme** : Méthode de la puissance itérée

---

**Entrées** :  $X \in \mathbb{R}^{n \times p}$ , itérations  $K$

$\mathbf{v}$  tiré aléatoirement dans  $\mathbb{R}^{n \times p}$  (e.g.,  $u/\|u\|$  avec  $u$  gaussien)

**pour**  $k = 1, \dots, K$  **faire**

$\mathbf{w} \leftarrow X \mathbf{v}$

$\mathbf{v} \leftarrow X^\top \mathbf{w}$

$\mathbf{v} \leftarrow \frac{\mathbf{v}}{\|\mathbf{v}\|}$

**Sorties** : Axe principale (approché)  $\mathbf{v}_1 = \mathbf{v}$

---

Rem: on résout une maximisation sous contrainte convexe

# Premier axe principal

Maximiser la fonction objectif suivante en  $\mathbf{v}$  :

$$\mathcal{L}(\mathbf{v}, \lambda) = (X\mathbf{v})^\top (X\mathbf{v}) - \lambda(\mathbf{v}^\top \mathbf{v} - 1) = \mathbf{v}^\top X^\top X \mathbf{v} - \lambda(\mathbf{v}^\top \mathbf{v} - 1)$$

$\lambda$  : multiplicateur de Lagrange

**Conditions d'optimalité du premier ordre en un extremum**

$$\frac{\partial \mathcal{L}(\mathbf{v}_1, \lambda)}{\partial \mathbf{v}} = 0 \Leftrightarrow X^\top X \mathbf{v}_1 = \lambda \mathbf{v}_1$$

La matrice de Gram  $X^\top X$  est diagonalisable (symétrique) donc si  $\mathbf{v}_1$  est un extremum alors c'est un vecteur propre.

Rem: on normalise  $\mathbf{v}_1$  pour que  $\|\mathbf{v}_1\| = 1$ , ainsi  $\lambda = \mathbf{v}_1^\top X^\top X \mathbf{v}_1$  et  $\mathbf{v}_1$  est un vecteur propre, de valeur propre  $\lambda$  maximale

# Aspect récursif de l'ACP - Déflation

Construction récursive : définir les axes principaux en partant du plus important et en descendant

Par récurrence, on définit le  $k^e$  axe pour qu'il soit orthogonal aux axes principaux précédents :

$$\mathbf{v}_k = \arg \max_{\mathbf{v} \in \mathbb{R}^p, \mathbf{v}^\top \mathbf{v}_1 = \dots = \mathbf{v}^\top \mathbf{v}_{k-1} = 0, \|\mathbf{v}\| = 1} \|X\mathbf{v}\|^2$$

- ▶ le premier axe maximise la variance des données projetées sur l'axe porté par ce vecteur
- ▶ le deuxième axe est celui orthogonal au premier, de variance projetée maximale
- ▶ etc.



# Nouvelle représentation des données

- ▶ Les axes (de direction)  $\mathbf{v}_1, \dots, \mathbf{v}_p \in \mathbb{R}^p$  sont appelés **axes principaux** ou **axes factoriels**, les nouvelles variables  $\mathbf{c}_j = X\mathbf{v}_j, j = 1, \dots, p$  sont appelées **composantes principales**

## Nouvelle représentation :

- ▶ La matrice  $XV_k$  (avec  $V_k = [\mathbf{v}_1, \dots, \mathbf{v}_k]$ ) est la matrice représentant les données dans la base des  $k$  premiers vecteurs propres

## Reconstruction dans l'espace original (débruiter) :

- ▶ Reconstruction "parfaite" pour  $\mathbf{x} \in \mathbb{R}^p$  :  $\mathbf{x} = \sum_{j=1}^p (\mathbf{x}^\top \mathbf{v}_j) \mathbf{v}_j$
- ▶ Reconstruction avec perte d'information :  $\hat{\mathbf{x}} = \sum_{j=1}^k (\mathbf{x}^\top \mathbf{v}_j) \mathbf{v}_j$

# Références I

- ▶ G. H. Golub and C. F. van Loan.

*Matrix computations.*

Johns Hopkins University Press, Baltimore, MD, third edition, 1996.